


Cours 4 : Introduction à l'apprentissage machine



La 4ème révolution industrielle

I. Machine learning


- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes



Intelligence artificielle : exemples d'application

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes




Détection de fraude




E-commerce




Véhicule autonome



Santé



Finance



Robotique

Cours 4 : Introduction à l'apprentissage machine

I. L'apprentissage machine

- A. Définition
- B. Comparaison avec la programmation classique
- C. Terminologie
- D. Classification
- E. Comparatif

II. L'apprentissage supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. Apprentissage non-supervisé

- A. Regroupement par K-moyennes

1

L'apprentissage machine

Qu'est-ce que l'intelligence artificielle ?

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif


II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- L'**intelligence artificielle** est un programme ou un modèle non humain qui peut résoudre des tâches sophistiquées, basé sur l'expérimentation.
- Officiellement, l'**apprentissage machine** (AM, *machine learning*) est un sous-domaine de l'intelligence artificielle. Ces dernières années, ces deux termes sont parfois utilisés de manière interchangeable par abus de langage.
- Arthur Samuel (pionnier l'IA et des jeux vidéos) : « **L'apprentissage machine est un domaine d'étude qui donne aux ordinateurs la capacité d'apprendre sans être explicitement programmés.** »



Programmation classique vs AM (1 / 2)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif


II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM


III. ML non supervisé

- A. K-moyennes

Programmation traditionnelle



Apprentissage machine



■ Dans la **programmation classique**, on alimente l'entrée, on programme la logique et on exécute le programme pour obtenir la sortie.

■ Dans l'**apprentissage automatique**, on alimente l'entrée et la sortie et l'exécutons sur la machine pendant la l'apprentissage.
 ■ la machine crée alors sa propre logique, qui est évaluée pendant le test.

Programmation classique vs AM (2 / 2)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes



Avantages

- Temps de développement beaucoup plus rapide (des jours contre des mois)
- Crédit de nouvelles possibilités
- Possibilité de trouver des modèles cachés
- Apprentissage local
- Diminution des faux positifs ou faux négatifs



Défis

- Il faut des données pour entraîner le modèle (étiquetées / sélectionnées)
- Couvre tous les scénarios possibles
- Le développement du bon modèle ou de la bonne inférence peut être complexe.
- Peut nécessiter l'expertise d'un scientifique et d'un spécialiste en ML
- Empreinte mémoire plus importante

Terminologie (1 / 2)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes

■ Un **modèle** (ou **hypothèse**) est une **représentation spécifique** apprise à partir de données en appliquant un algorithme d'apprentissage automatique.

■ Une **caractéristique** est une propriété individuelle mesurable de nos données.

■ Un ensemble de caractéristiques numériques peut être décrit de manière pratique par un **vecteur de caractéristiques**. Les vecteurs de caractéristiques sont introduits dans le modèle (AM supervisé).

Par exemple, pour prédire un fruit, il peut y avoir des caractéristiques comme la couleur, l'odeur, le gout, etc.



Terminologie (2 / 2)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif


II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- Une **cible** (= un **label**) est variable ou une étiquette cible est la valeur à prédire par notre modèle. Pour l'exemple des fruits abordé dans la section sur les caractéristiques, l'étiquette de chaque ensemble d'entrées serait le nom du fruit, comme pomme, orange, banane, etc.
- Une **formation** : L'idée est de donner un ensemble d'entrées (caractéristiques) et les sorties attendues (étiquettes), ainsi après la formation, nous aurons un modèle (hypothèse) qui fera correspondre les nouvelles données à l'une des catégories formées.
- Une **prédiction** : Une fois que notre modèle est prêt, il peut être alimenté par un ensemble d'entrées auxquelles il fournira une sortie prédite (étiquette).



Classification

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif


II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ Selon si l'algorithme est entraîné sur des données d'entraînement bien définies (vecteur de caractéristiques) ou non, on parle d'**apprentissage machine supervisé** ou **non supervisé**.



Classification : Apprentissage supervisé (1 / 3)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Démarche

① Subdivision des observations en :


- Observations pour l'apprentissage
- Observations pour la validation

② Apprentissage du modèle

③ Validation du modèle

④ Prédiction sur de nouvelles observations

EXEMPLE



Classification : Apprentissage supervisé (2 / 3)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif



II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- Défini pour un **modèle** entraîné sur un ensemble de données **étiquetées**.
- L'ensemble **étiqueté** est défini par les caractéristiques et les prédictions.



Classification : Apprentissage supervisé (3 / 3)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ **Régression:** Il s'agit d'une tâche d'apprentissage supervisé où la sortie a une **valeur continue**.

■ **Classification :** Il s'agit d'un type d'apprentissage supervisé où la sortie a des **étiquettes définies** (valeur discrète). Il peut s'agir d'une classification binaire ou multi-classes. Dans la classification **binaire**, le modèle prédit soit 0 ou 1 : oui ou non, mais dans le cas de la classification **multi-classes**, le modèle prédit plus d'une classe.

■ L'inconvénient le plus fondamental de tout algorithme d'**apprentissage supervisé** est que l'ensemble de données doit être étiqueté à la main, soit par un ingénieur en apprentissage automatique, soit par un scientifique des données. Il s'agit d'un *processus très coûteux*, surtout lorsqu'il s'agit de traiter de grands volumes de données.

EXEMPLES



Quelle va être la vitesse du vent demain ?
Quelle sera la température de demain ?



Est-ce que cette personne a le profil d'un acheteur potentiel ?
Va-t-il faire chaud demain ?

| Temperature | Pressure | Relative Humidity | Wind Direction | Wind Speed |
|-------------|-------------|-------------------|----------------|-------------|
| 10.69261758 | 986.882019 | 54.19337313 | 195.7150879 | 3.278597116 |
| 13.59184184 | 987.8729248 | 48.0648859 | 189.2951202 | 2.909167767 |
| 17.70494885 | 988.1119385 | 39.11965597 | 192.9273834 | 2.973036289 |
| 20.95430404 | 987.8500366 | 30.66273218 | 202.0752863 | 2.965289593 |
| 22.9278274 | 987.2833862 | 26.06723423 | 210.6589203 | 2.798230886 |
| 24.04233986 | 986.2907104 | 23.46918024 | 221.1188503 | 2.627005816 |
| 24.41475295 | 985.2338867 | 22.25082295 | 233.7911982 | 2.448749781 |
| 23.93361956 | 984.8914795 | 22.35178837 | 244.3504333 | 2.454271793 |
| 22.68800023 | 984.8461304 | 23.7538641 | 253.0864710 | 2.418341875 |
| 20.56425726 | 984.8380737 | 27.07867944 | 264.5071106 | 2.318677425 |
| 17.76400389 | 985.4262085 | 33.54900114 | 280.7827454 | 2.143950987 |

Régression

| User ID | Gender | Age | Salary | Purchased |
|----------|--------|-----|--------|-----------|
| 15624510 | Male | 19 | 1900 | 0 |
| 15810944 | Male | 35 | 2000 | 1 |
| 15668575 | Female | 26 | 4300 | 0 |
| 15603246 | Female | 27 | 5700 | 0 |
| 15804002 | Male | 19 | 7600 | 1 |
| 15728773 | Male | 27 | 5800 | 1 |
| 15598044 | Female | 27 | 8400 | 0 |
| 15694829 | Female | 32 | 15000 | 1 |
| 15600575 | Male | 25 | 13000 | 1 |
| 15727311 | Female | 35 | 6500 | 0 |
| 15570769 | Female | 26 | 8000 | 1 |
| 15606274 | Female | 26 | 5200 | 0 |

Classification

Classification : Apprentissage non supervisé (1 / 3)

I. Machine learning


- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes



Classification : Apprentissage non supervisé (2 / 3)

I. Machine learning


- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes



Classification : Apprentissage non supervisé (3 / 3)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

EXAMPLE

Déterminer le type de fruit sans avoir au préalable des données étiquetées.



Classification : Apprentissage semi-supervisé

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes

■ Pour contrer ces inconvénients, le concept d'**apprentissage semi-supervisé** a été introduit.

■ Dans ce type d'apprentissage, l'algorithme est entraîné sur une combinaison de données étiquetées et non étiquetées.

■ En général, cette combinaison contient une très petite quantité de données étiquetées et une très grande quantité de données non étiquetées.

■ Dans l'apprentissage semi-supervisé, les données étiquetées sont utilisées pour apprendre un modèle et, à l'aide de ce modèle, les données non étiquetées sont étiquetées, ce que l'on appelle le **pseudo-étiquetage**, et en utilisant l'ensemble des données, le modèle est formé pour une utilisation ultérieure.



Classification : Apprentissage par renforcement

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification**
- E. Comparatif

II. ML supervisé


- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ L'**apprentissage par renforcement** (ou auto supervisé) est la formation continue d'une machine à partir d'expériences de façon à optimiser une récompense quantitative au cours du temps.

■ Le système prend des décisions en fonction de son état courant et reçoit une **récompense** (positive ou négative) en fonction de son action. L'objectif est de bâtir un comportement décisionnel qui permet d'optimiser les gains au cours du temps.



Comparatif des méthodes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes



| | Supervisé | Non-supervisé | Par renforcement |
|-----------------------|--|---|---|
| Caractéristiques clés | Les données fournies sont étiquetées par des humains. | Les machines (ordinateurs) cherchent des tendances dans les données qui sont difficiles à étiqueter pour les humains. | La machine crée ses propres données et supervise elle-même son apprentissage. |
| Champs d'utilisation | La tâche à exécuter est connue et exige un temps considérable. | Nous voulons découvrir des tendances inconnues dans les données. | Nous avons un objectif, mais ignorons peut-être le meilleur moyen de l'atteindre. |

2

L'apprentissage supervisé



régression

Régression linéaire (1 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ La **régression linéaire** est utilisée pour montrer ou prédire la relation entre deux variables ou facteurs afin de **prédir une quantité continue**.

■ L'hypothèse de départ est que **le phénomène a un comportement linéaire**.


Fonction de prédiction linéaire

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

FAUX EXEMPLES




Chien ou chat ?
→ classification



Quelle est la puissance dissipée si $i = 20 \text{ mA}$?
 $P = ri^2$ non linéaire
 → pas de régression linéaire



Dégâts d'un séisme en fonction de la magnitude de Richter
 → Échelle de Richter = discret donc non applicable.



Régression linéaire (2 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes

- Le facteur qui est prédit est appelé **variable dépendante**
- Les facteurs qui sont utilisés pour prédire la variable dépendante sont appelés **variables indépendantes**.
- On cherche un couple de paramètres (θ_0, θ_1) pour que la fonction $h_\theta(x)$ soit proche de y pour notre exemple d'entraînement (x, y) .

Fonction coût pour une régression simple


$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2$$

- Hypothèse : $h_\theta(x) = \theta_0 + \theta_1 x$ (relation linéaire)
- Paramètres : θ_0, θ_1
- Objectif : minimiser la fonction de coût $J(\theta_0, \theta_1)$
= erreur quadratique moyenne



Remarque :

- $h_\theta(x^{(i)}) - y^{(i)}$ est la différence entre le point de mesure et la fonction de prédiction h_θ
- On l'élève au carré pour avoir la norme euclidienne plutôt que de prendre la valeur absolue



Régression linéaire (3 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Algorithme

Répéter jusqu'à convergence :

```
{
    temp0 :=  $\theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$ 
    temp1 :=  $\theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$ 
     $\theta_0 := \text{temp0}$ 
     $\theta_1 := \text{temp1}$ 
}
```


α : taux d'apprentissage


$\frac{\partial}{\partial \theta_i} J(\theta_0, \theta_1)$: dérivée partielle
de la fonction coût

Remarque :

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)}$$





régression

Régression linéaire (4 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM




III. ML non supervisé

- A. K-moyennes


- On parle de **descente de gradient** lorsque l'on cherche à optimiser la fonction de coût $J(\theta_0, \theta_1)$:


$$\theta_i = \theta_i - \alpha \frac{\partial}{\partial \theta_i} J(\theta_0, \theta_1)$$

- Cette technique a pour avantage de moins surcharger la mémoire qu'une résolution directe.



- Le choix du **taux d'apprentissage** (*learning rate*) est important et conditionne le temps de calcul.





régression

Régression linéaire (5 / 6)

I. Machine learning


- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes




EXEMPLE

Prévision des émissions de CO_2 en fonction de la taille du moteur à l'aide d'une régression linéaire simple

| | ENGINESIZE | CYLINDERS | FUELCONSUMPTION_COMB | CO2EMISSIONS |
|---|------------|-----------|----------------------|--------------|
| 0 | 2.0 | 4 | 8.5 | 196 |
| 1 | 2.4 | 4 | 9.6 | 221 |
| 2 | 1.5 | 4 | 5.9 | 136 |
| 3 | 3.5 | 6 | 11.1 | 255 |
| 4 | 3.5 | 6 | 10.6 | 244 |
| 5 | 3.5 | 6 | 10.0 | 230 |
| 6 | 3.5 | 6 | 10.1 | 232 |
| 7 | 3.7 | 6 | 11.1 | 255 |
| 8 | 3.7 | 6 | 11.6 | 267 |
| 9 | 2.4 | 4 | 9.2 | ? |





Régression linéaire (6 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Algorithme

➊ Initialisation

```

 $n \leftarrow 0;$ 
 $\theta_0^0 \leftarrow 0;$ 
 $\theta_1^0 \leftarrow 0;$ 
 $m := \text{taille de vecteur } data;$ 
 $\text{erreur} := 0;$ 
 $\text{lire vecteur } x(1:m);$ 
 $\text{lire vecteur } y(1:m);$ 
  
```


➋ Entrainement

```

do
{
     $\theta_0^{n+1} := \theta_0^n - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)});$ 
     $\theta_1^{n+1} := \theta_1^n - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)};$ 
     $n := n + 1;$ 
     $\text{erreur} = \text{erreur} + (h_\theta(x^{(i)}) - y^{(i)})^2;$ 
}
while (erreur < 1e - 6)
 $\theta_0 := \theta_0^{n+1};$ 
 $\theta_1 := \theta_1^{n+1};$ 
  
```

➌ Prédiction

$\text{lire } x(m+1);$
 $y(m+1) := \theta_1 x(m+1) + \theta_0$



Régression linéaire : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

EXEMPLE

Température en fonction de l'altitude



Un relevé de gradients de température dans des stations d'altitudes différentes donne :


| i | $x^{(i)}$ | $y^{(i)}$ |
|-----|-----------|-----------|
| 1 | 2 | 0 |
| 2 | 3 | 1 |
| 3 | 4 | 2 |
| 4 | 7 | ? |

On émet l'hypothèse que la relation entre l'altitude et la température est linéaire, selon l'équation de prédiction suivante :

$$h_{\theta} = \theta_0 + \theta_1 x$$

Calculer le couple de coefficients (θ_0, θ_1) permettant de prédire le gradient de température à une altitude donnée, et prédire celle pour une altitude de 7 u.a..

On prendra $\alpha = 0,25$



régression

Régression linéaire : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

On a $\alpha = 0,25$ et $m = 3$

La descente de gradient donne

$$\frac{\partial \theta_j}{\partial t} = -\frac{\partial}{\partial \theta_j} J(\theta) \quad \text{avec} \quad \begin{cases} \frac{\partial}{\partial \theta_0} J(\theta) = -\frac{1}{m} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}), \\ \frac{\partial}{\partial \theta_1} J(\theta) = -\frac{1}{m} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} \end{cases}$$

Une approximation par différence finie donne :

$$\frac{\partial \theta_j}{\partial t} \approx \frac{\theta_j^{n+1} - \theta_j^n}{\alpha} \quad \Leftrightarrow \quad \begin{cases} \theta_0^{n+1} = \theta_0^n - \frac{\alpha}{m} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}), \\ \theta_1^{n+1} = \theta_1^n - \frac{1}{4} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} \end{cases}$$

| i | $x^{(i)}$ | $y^{(i)}$ |
|-----|-----------|-----------|
| 1 | 2 | 0 |
| 2 | 3 | 1 |
| 3 | 4 | 2 |
| 4 | 7 | ? |

On fixe les conditions initiales sont : $\theta_0^0 = 0$ et $\theta_1^0 = 0$

$$h_\theta(x^{(i)}) = 0$$

Itération $n = 1$

$$\theta_0^1 = -\frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) = \frac{0 + 1 + 2}{12} = 0,25$$

$$\theta_1^1 = -\frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = \frac{0 + 3 + 8}{12} = 0,915$$

$h_\theta(x^{(i)}) = 0,25 + 0,915 * x^{(i)}$


Itération $n = 2$

$$\theta_0^2 = \theta_0^1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) = 0,25 - \frac{2,08 + 1,995 + 1,91}{12} = -0,25$$

$$\theta_1^2 = \theta_1^1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = 0,915 - \frac{9,32 + 16,47 + 25,28}{12} = 1,48$$

$h_\theta(x^{(i)}) = -0,25 + 1,48 * x^{(i)}$

Régression linéaire : Exemple



régression

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Itération $n = 3$

$$\theta_0^2 = \theta_0^1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) = -0,25 - \frac{2,71 + 3,69 + 4,17}{12} = \textcolor{blue}{-1,45}$$

$$\theta_1^2 = \theta_1^1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = 1,485 - \frac{5,42 + 9,57 + 14,68}{12} = \textcolor{blue}{2,47}$$

$$h_\theta(x^{(i)}) = \textcolor{blue}{-1,45 + 2,47 * x^{(i)}}$$

| i | $x^{(i)}$ | $y^{(i)}$ |
|-----|-----------|-----------|
| 1 | 2 | 0 |
| 2 | 3 | 1 |
| 3 | 4 | 2 |
| 4 | 7 | ? |

Itération $n = 4$

$$\theta_0^3 = \theta_0^2 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) = 1,45 - \frac{3,49 + 2,96 + 6,43}{12} = \textcolor{blue}{-2,52}$$

$$\theta_1^3 = \theta_1^2 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = 2,47 - \frac{6,98 + 8,88 + 25,72}{12} = \textcolor{blue}{1}$$


$$h_\theta(x^{(i)}) = \textcolor{blue}{-2,52 + x^{(i)}}$$


Application numérique pour

$$h_\theta(x^{(4)}) = 7 * 1 - 2,52 = \textcolor{blue}{4,48}$$

Remarque 1 : en continuant à itérer, on aurait plus de chiffres significatifs corrects.

Remarque 2 : en choisissant un α plus petit, on pourrait converger plus vite.





Régression logistique

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ La **régression logistique** est un algorithme qui est utilisé pour résoudre les problèmes de **classification** sur des **variables discrètes**.

Il s'agit d'une analyse prédictive qui décrit les données et explique la relation entre les variables.

■ En fonction du nombre de catégories, la régression logistique peut être considérée comme :

► **Binomiale** : La variable cible ne peut avoir que 2 types possibles : "0" ou "1"


► **Multinomiale** : La variable cible peut avoir 3 types possibles ou plus qui ne sont pas ordonnés
Exemple: "maladie A" vs "maladie B" vs "maladie C".


► **Ordinal** : le résultat de test peut être classé dans les catégories suivantes variables cibles avec des catégories ordonnées.

Par exemple, : "très mauvais", "mauvais", "bon", "très bon".

Ici, chaque catégorie peut recevoir un score comme 0, 1, 2, 3.

EXEMPLES





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ La **régression logistique binomiale** est appliquée à une variable d'entrée (x) où la variable de sortie (y) est une valeur discrète comprise entre 1 (oui) et 0 (non). Ce modèle peut être étendu pour modéliser plusieurs classes d'événements, par exemple pour déterminer si une image contient un chat, un chien, un lion, etc.


Approche naïve : faire une régression linéaire pour séparer les deux clusters


EXEMPLE

Dire si une tumeur est maligne ou non en fonction de sa taille

Inconvénients :

- 👎 Une régression linéaire donnerait des valeurs autres que 0 ou 1
- 👎 La régression linéaire est sensible aux points extrêmes : un point aberrant changerait le seuil.
- 👎 La pente de la régression linéaire change en fonction du nombre de points sur les deux plateaux (0 et 1)





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

- On parle de **régression logistique** lorsque l'on utilise une fonction de prédiction de type logistique (= sigmoïde).
- L'hypothèse $h_\theta(x)$ produit un nombre entre 0 et 1, que l'on peut interpréter comme étant une probabilité.



Fonction de prédiction logistique


$$h_\theta(x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Avantages :



Valeurs entre 0 et 1





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

- On peut alors écrire qu'il s'agit de la probabilité que $y = 1$ étant donné x , paramétré par θ :

Forme probabilistique de $h_\theta(x)$

$$h_\theta(x) = P(y = 1|x ; \theta)$$

Il s'agit alors d'une tâche de **classification** ($y = 0$ ou 1), et :

$$P(y = 1|x ; \theta) + P(y = 0|x ; \theta) = 1$$


$$\Leftrightarrow P(y = 0|x ; \theta) = 1 - P(y = 1|x ; \theta)$$


- Lorsque la probabilité que y soit égale à 1 est supérieure ou égale à 0,5, on peut prédire que $y = 1$. Sinon, on prédit que $y = 0$

- Il est alors courant de noter $\theta^T x = z$ et de centrer en 0 la valeur seuil de 0,5.
- On a donc :

Si $z \geq 0$ alors $y = 1$

Si $z \leq 0$, alors $y = 0$





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé


- A. K-moyennes

EXEMPLE 1

On considère $h_\theta(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2) = g(\theta^T x)$ avec θ^T le vecteur ligne $[-3 \quad 1 \quad 1]$

On prédit alors $y = 1$ si $-3 + x_1 + x_2 \geq 0$
 $\Leftrightarrow y = 1$ si $x_1 + x_2 \geq 3$

La droite $x_1 + x_2 = 3$ est alors la **frontière de décision**.





EXEMPLE 2

On considère $h_\theta(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2) = g(\theta^T x)$ avec θ^T le vecteur ligne $[-1 \quad 0 \quad 0 \quad 1 \quad 1]$

On prédit alors $y = 1$ si $x_1^2 + x_2^2 \geq 1$

La **frontière de décision** est donc $x_1^2 + x_2^2 = 1$





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé


- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes


EXEMPLE 1


Prédire le mouvement d'une main en utilisant une centrale inertielle.



EXEMPLE 2

Prédire la trajectoire que doit suivre un robot en anticipant les prochaines directions.





Régression logistique binaire

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

Algorithme

➊ Initialisation

```

 $n \leftarrow 0;$ 
 $\theta_0^0 \leftarrow 0;$ 
 $\theta_1^0 \leftarrow 0;$ 
 $m := \text{taille de vecteur data};$ 
 $\text{erreur} := 0;$ 
 $\text{lire vecteur } x(1:m);$ 
 $\text{lire vecteur } y(1:m);$ 

```

➋ Entrainement


```

do
{
     $\theta_0^{n+1} := \theta_0^n - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) h_\theta(x^{(i)})(1 - h_\theta(x^{(i)}));$ 
     $\theta_1^{n+1} := \theta_1^n - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) h_\theta(x^{(i)})(1 - h_\theta(x^{(i)})) x^{(i)};$ 
     $n := n + 1;$ 
     $\text{erreur} = \text{erreur} + (h_\theta(x^{(i)}) - y^{(i)})^2;$ 
}
while (erreur < 1e-6)
 $\theta_0 := \theta_0^{n+1};$ 
 $\theta_1 := \theta_1^{n+1};$ 

```

➌ Prédiction

$\text{lire } x(m+1);$
 $y(m+1) := \theta_1 x(m+1) + \theta_0$



Régression logistique : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

EXEMPLE

Radar de sécurité pour la détection de piétons embarqué dans une voiture.



Le tableau suivant présente un relevé de distance entre les piétons et le parechoc avant de la voiture, et le message d'avertissement à remonter au conducteur :


| <i>i</i> | $x^{(i)} [m]$ | $y^{(i)}$ | label |
|----------|---------------|-----------|-------------|
| 1 | -2 | 0,08 | Très proche |
| 2 | -1 | 0,27 | proche |
| 3 | 0 | 0,5 | loin |
| 4 | 2 | 0,97 | Très loin |
| 5 | 1,5 | ? | ? |

On émet l'hypothèse que la relation entre la distance entre le parechoc et le piéton, et l'intensité de l'avertisseur sonore n'est pas linéaire, mais suit la relation suivante :

$$h_{\theta} = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Calculer le couple de coefficients (θ_0, θ_1) permettant de prédire si le piéton est « très proche », « proche », « loin », ou « très loin » en fonction de la distance, et prédire si un piéton situé à 1,5 m est considéré comme « proche » ou « très proche ».

On prendra $\alpha = 0,25$ et $m = 4$



Régression logistique : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

EXEMPLE

Avec les paramètres $\alpha = 0,25$ et $m = 4$, la descente de gradient donne :

$$\frac{\partial \theta_j}{\partial t} = -\alpha \frac{\partial}{\partial \theta_j} J(\theta) \text{ avec } \begin{cases} \frac{\partial}{\partial \theta_0} J(\theta) = -\frac{0,25}{4} \sum_{i=1}^4 h_\theta(x^{(i)}) - y^{(i)} \\ \frac{\partial}{\partial \theta_1} J(\theta) = -\frac{0,25}{4} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} \end{cases}$$

Une approximation par différence finie donne :

$$\frac{\partial \theta_j}{\partial t} \approx \frac{\theta_j^{n+1} - \theta_j^n}{\alpha} \text{ d'où : } \begin{cases} \frac{\partial}{\partial \theta_0} J(\theta) = \theta_0^n - \frac{0,25}{3} \sum_{i=1}^4 h_\theta(x^{(i)}) - y^{(i)} \\ \frac{\partial}{\partial \theta_1} J(\theta) = \theta_1^n - \frac{0,25}{3} \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} \end{cases}$$

On fixe les conditions initiales : $\theta_0^0 = 0$ et $\theta_1^0 = 0$

$$h_\theta(x^{(i)}) = 0,5$$


Itération $n = 1$

$$\theta_0^1 = -\frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = \frac{1}{4 \cdot 4} \sum_{i=1}^4 0,5 - y^{(i)} = \mathbf{0,011}$$

$$\theta_1^1 = -\frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = \frac{1}{4 \cdot 4} \sum_{i=1}^4 (0,5 - y^{(i)}) \cdot x^{(i)} = \mathbf{-0,125}$$

$$h_\theta(x) = \frac{1}{1 + e^{-(0,011 - 0,125x^{(i)})}}$$

| i | $x^{(i)} [m]$ | $y^{(i)}$ | label |
|-----|---------------|-----------|-------------|
| 1 | -2 | 0,08 | Très proche |
| 2 | -1 | 0,27 | proche |
| 3 | 0 | 0,5 | loin |
| 4 | 2 | 0,97 | Très loin |
| 5 | 1,5 | ? | ? |



Régression logistique : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

Itération $n = 2$

$$\theta_0^2 = \theta_0^1 - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = 0,011 - \frac{0,35 + 0,19 - 0,0022 - 0,41}{4 \cdot 4} = \mathbf{0,003}$$

$$\theta_1^2 = \theta_1^1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = -0,125 - \frac{-0,7 - 0,19 + 0 - 0,82}{4 \cdot 4} = \mathbf{-0,017}$$

$$h_\theta(x) = \frac{1}{1 + e^{-(0,003-0,017x^{(i)})}}$$

Itération $n = 3$

$$\theta_0^3 = \theta_0^2 - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = 0,003 - \frac{0,41 + 0,225 - 0,00075 - 0,46}{4 \cdot 4} = \mathbf{-0,008}$$

$$\theta_1^3 = \theta_1^2 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = -0,017 - \frac{-0,821 - 0,225 + 0 - 0,92}{4 \cdot 4} = \mathbf{0,105}$$


$$h_\theta(x) = \frac{1}{1 + e^{(-0,008+0,105x^{(i)})}}$$

Itération $n = 4$

$$\theta_0^4 = \theta_0^3 - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = \mathbf{-0,21}$$

$$\theta_1^4 = \theta_1^3 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = \mathbf{0,245}$$

$$h_\theta(x) = \frac{1}{1 + e^{(-0,21+0,245x^{(i)})}}$$



Régression logistique : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes

Itération $n = 5$

$$\theta_0^5 = \theta_0^4 - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = 0,003 - \frac{0,41 + 0,225 - 0,00075 - 0,46}{4 \cdot 4} = \textcolor{blue}{-0,21}$$

$$\theta_1^5 = \theta_1^4 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = -0,017 - \frac{-0,821 - 0,225 + 0 - 0,92}{4 \cdot 4} = \textcolor{blue}{0,245}$$

$$h_\theta(x) = \frac{1}{1 + e^{-(-0,008-0,105x^{(i)})}}$$

Itération $n = 6$

$$\theta_0^6 = \theta_0^5 - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = 0,21 - \frac{0,54 - 0,29 + 0,005 - 0,585}{4 \cdot 4} = \textcolor{blue}{-0,03}$$

$$\theta_1^6 = \theta_1^5 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = 0,245 - \frac{-1,09 - 0,29 + 0 - 1,17}{4 \cdot 4} = \textcolor{blue}{0,405}$$


$$h_\theta(x) = \frac{1}{1 + e^{-(-0,03+0,405x^{(i)})}}$$

Itération $n = 20$

$$\theta_0^{20} = \theta_0^{19} - \frac{\alpha}{m} \sum_{i=1}^m h_\theta(x^{(i)}) - y^{(i)} = \textcolor{blue}{-0,21}$$

$$\theta_1^{20} = \theta_1^{19} - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x^{(i)} = \textcolor{blue}{0,245}$$

$$h_\theta(x) = \frac{1}{1 + e^{-(-0,21+0,245x^{(i)})}}$$



Régression logistique : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique**
- C. SVM

III. ML non supervisé

- A. K-moyennes




$$h_{\theta}(-2) = \frac{1}{1 + e^{-(0,21+0,245 \cdot (-2))}} = \mathbf{0,0759}$$

$$h_{\theta}(-1) = \frac{1}{1 + e^{-(0,21+0,245 \cdot (-1))}} = \mathbf{0,2689}$$

$$h_{\theta}(-0,5) = \frac{1}{1 + e^{-(0,21+0,245 \cdot (-0,5))}} = \mathbf{0,4378}$$

$$h_{\theta}(1,5) = \frac{1}{1 + e^{-(0,21+0,245 \cdot 1,5)}} = \mathbf{0,9399}$$



Classification multi-classe

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM


III. ML non supervisé

- A. K-moyennes


- Lorsque l'on a plus de deux classes à discriminer, on applique une classification « un contre tous » : pour n classes, on ramène le problème à n problèmes de classification binaire distincts.

- Par exemple pour $n = 3$:

- Bleu (1) vs rouge et jaune (0) $h_{\theta}^1(x) : P(y = 1|x_1; \theta)$
- Rouge (1) vs jaune et bleu (0) $h_{\theta}^1(x) : P(y = 1|x_2; \theta)$
- Jaune (1) vs bleu et rouge (0) $h_{\theta}^1(x) : P(y = 1|x_3; \theta)$



- On entraîne alors le classificateur de régression logistique $h_{\theta}^{(i)}(x)$ pour chaque classe i afin de prédire la probabilité que $y = i$
- Sur une nouvelle entrée x , on choisit la classe i qui maximise la probabilité que $h_{\theta}^{(i)}(x) = 1$



Classification multi-classe

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

■ Hypothèse :

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2 + \theta_6 x_1^3 x_2 + \theta_7 x_1 x_2^3 + \dots)$$

Fonction coût pour une régression logistique régularisée

$$J(\theta) = \frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) + \frac{\lambda}{2} \sum_{j=1}^n \theta_j^2 \right]$$

Algorithme

Répéter $\min_{\theta} J(\theta)$:


$$\begin{aligned} \{ & \quad \theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \\ & \quad \theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \lambda \theta_j \right] \end{aligned}$$


Mise à jour des θ_j

}

EXEMPLE

Classifier les voix dans une salle en utilisant plusieurs microphones.





Séparateur à Vaste Marge (1 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM**

III. ML non supervisé


- A. K-moyennes

- Le **Séparateur à vaste marge** (SVM) permet également de traiter les problèmes de classification supervisés en maximisant la marge (distance) entre les échantillons proches de la frontière de décision, appelés **vecteurs support**.
- On utilise une fonction coût similaire à celle utilisée pour la régression logistique, mais avec quelques changements.

Avant changement :

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

$$\text{Prédire } y = \begin{cases} 1 & \text{si } h_{\theta}(x) \geq 0,5 \text{ si } \theta^T x \gg 0 \text{ pour avoir } h_{\theta}(x) \approx 1 \\ 0 & \text{si } h_{\theta}(x) < 0,5 \text{ si } \theta^T x \ll 0 \text{ pour avoir } h_{\theta}(x) \approx 0 \end{cases}$$




- Afin de pouvoir optimiser les paramètres, il faut que la fonction coût $J(\theta)$ soit une **fonction convexe** : la descente de gradient doit converger vers un minimum local.

Or cela peut ne pas être le cas ici (fonction non convexe → plusieurs optimums locaux et la descente de gradient peut rester bloquée dans un minimum local.)

- Pour contourner ce problème, on utilise une fonction coût différente, qui cette fois-ci est convexe :

$$J(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{si } y = 0 \end{cases}$$



Séparateur à Vaste Marge (2 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Fonction coût convexe

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))$$

- Il convient alors d'appliquer l'algorithme de descente de gradient sur $J(\theta)$ pour chaque paramètre :

Algorithme


Répéter $\min_{\theta} J(\theta)$:


{

$$\theta_j^{n+1} = \theta_j^n - C \sum_{i=1}^m y^{(i)} (1 - h_\theta(x^{(i)})) - (1 - y^{(i)}) h_\theta(x^{(i)}) + \theta_j^n$$

Mise à jour des θ_j

}





Séparateur à Vaste Marge (3 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Fonction coût SVM


$$J(\theta) = C \sum_{i=1}^m y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))$$

- Lorsque la valeur de C est très grande, il convient d'écrire $J(\theta)$ pour chaque paramètre :

Fonction coût SVM à grand paramètre C

$$J(\theta) = \begin{cases} \min_{\theta} \left(\sum_{i=1}^n \theta_i^2 \right) \\ \text{sous contrainte :} \\ y = 1 \text{ si } \theta^T x^{(i)} \geq 1 \\ y = 0 \text{ si } \theta^T x^{(i)} \leq 1 \end{cases}$$

- On dit que les échantillons sont linéairement séparables si Les prédictions $y^{(i)} = \begin{cases} 1 & \text{si } \theta^T x^{(i)} \geq 1 \\ 0 & \text{si } \theta^T x^{(i)} \leq -1 \end{cases}$
- Les prédictions sont alors contrôlées par la largeur de la marge.



Séparateur à Vaste Marge (4 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM


III. ML non supervisé

- A. K-moyennes


- Il convient également de rendre plus discriminant les conditions aux limites :

$$\text{Prédire } y = \begin{cases} 1 & \text{si } h_{\theta}(x) \geq 0,5 \text{ si } \theta^T x \gg 0 \\ 0 & \text{si } h_{\theta}(x) < 0,5 \text{ si } \theta^T x \ll 0 \end{cases}$$

$$\text{Prédire } y = \begin{cases} 1 & \text{si } h_{\theta}(x) \geq 0,5 \text{ si } \theta^T x \geq 0 \\ 0 & \text{si } h_{\theta}(x) < 0,5 \text{ si } \theta^T x \leq 0 \end{cases}$$



$$J(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$



Séparateur à Vaste Marge (5 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- Il est nécessaire de représenter graphiquement l'écart entre la prediction positif et négatif par une marge de sécurité notée M :


Marge de sécurité M


$$M = \frac{\theta_1 \cdot x^+ + \theta_0 - \theta_1 \cdot x^- - \theta_0}{|\theta_1|} = \frac{(x^+ - x^-) \cdot \theta_1}{|\theta_1|} = \frac{2}{|\theta_1|}$$

- La marge M donnée par l'écart normalisé entre la frontière de prédiction positive et la frontière de prédiction négative est :

- $y = +1 = \theta_1 \cdot x^+ + \theta_0$
- $y = -1 = \theta_1 \cdot x^- + \theta_0$

- On cherche à **maximiser** cette marge.





Séparateur à Vaste Marge (6 / 6)

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- La fonction coût $J(\theta)$ permettant de maximiser la marge est dite **fonction de coût charnière**.
- L'apprentissage est similaire à celui qui a été vu précédemment.

Algorithme

Répéter $\min_{\theta} J(\theta)$:

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

$$\theta_0 := \theta_0 - \alpha C \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$


$$\theta_j := \theta_j - \alpha \left[C \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} + \theta_j \right]$$


Mise à jour des θ_j

}

EXEMPLE

Contrôler l'éclairage d'une salle à l'aide de 2 capteurs au lieu de la salle et compléter l'homogénéité d'éclairage par 6 autres capteurs répartis dans la salle





Astuce du noyau

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- La SVM fait l'hypothèse que les groupes sont **linéairement séparables**, mais ce n'est pas toujours le cas en pratique.
- L'**astuce du noyau** permet de représenter la non-séparabilité entre les groupes. Elle consiste à :
 - plonger les données dans un nouvel espace appelé **espace de features** ;
 - appliquer une svm sur les features.
- Le terme **astuce** vient du fait que ce procédé ne nécessite pas de connaître explicitement les features: pour résoudre le problème de la SVM on a juste besoin de connaître le **noyau** associé au features. D'un point de vu formel un noyau est une fonction mathématique simple (il en existe plusieurs sortes avec des propriétés différentes...) :

Fonction coût SVM avec noyau

$$J(\theta) = C \sum_{i=1}^m y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) + \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

Fonction coût SVM avec noyau


$$J(\theta) = C \sum_{i=1}^m y^{(i)} J_1(\theta^T f^{(i)}) + (1 - y^{(i)}) J_0(\theta^T f^{(i)}) + \frac{1}{2} \sum_{i=1}^n \theta_i^2$$


Exemple de features :

$f_1 = x_1, f_2 = x_2, f_3 = x_1 \cdot x_2$, etc.

EXAMPLE

Couplage Optique entre les 8 capteurs pour détection du bon électrage dans une sale.





Séparateur à Vaste Marge : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes


EXEMPLE

Classer les zones de l'aile d'un avion pour savoir si elles sont d'une température très différente (+1) ou non (-1) du fuselage de l'avion*.



Le tableau suivant présente pour différents couples de coordonnées $(x^{(i)}, y^{(i)})$ un label correspondant au gradient de température entre le fuselage de l'avion et le point de mesure :


| i | $x^{(i)} [m]$ | $y^{(i)} [m]$ | label |
|-----|---------------|---------------|-------|
| 1 | 1 | 2 | +1 |
| 2 | 1,5 | 1,5 | +1 |
| 3 | 1 | 0,5 | -1 |
| 4 | 2 | 2 | +1 |
| 5 | 2,5 | 3 | ? |



On émet l'hypothèse que la température en fonction de l'éloignement du fuselage est une fonction non linéaire de la forme suivante :

$$h_{\theta} = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

*il est parfois difficile voire impossible de tout modéliser ou de placer des capteurs à certains endroits.



Séparateur à Vaste Marge : Exemple

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

On prend $\alpha = 0,25$ et $m = 4$

La descente de gradient donne :

$$\frac{\partial \theta_j}{\partial t} = -\frac{\partial}{\partial \theta_j} J(\theta) \text{ avec } \begin{cases} \frac{\partial}{\partial \theta_0} J(\theta) = -C\alpha \sum_{i=1}^4 h_\theta(x^{(i)}) - y^{(i)} \\ \frac{\partial}{\partial \theta_1} J(\theta) = -C\alpha \sum_{i=1}^4 (h_\theta(x^{(i)}) - y^{(i)})x^{(i)} - \lambda\theta_1 \end{cases}$$

Itération 1


| <i>i</i> | <i>x</i>⁽ⁱ⁾ [m] | <i>y</i>⁽ⁱ⁾ [m] | label |
|-----------------|-----------------------------------|-----------------------------------|--------------|
| 1 | 1 | 2 | -1 |
| 2 | 1,5 | 1,5 | -1 |
| 3 | 1 | 0,5 | -1 |
| 4 | 2 | 2 | +1 |
| 5 | 2,5 | 3 | +1 |

Itération 2

| <i>i</i> | <i>x</i>⁽ⁱ⁾ [m] | <i>y</i>⁽ⁱ⁾ [m] | label |
|-----------------|-----------------------------------|-----------------------------------|--------------|
| 1 | 1 | 2 | -1 |
| 2 | 1,5 | 1,5 | -1 |
| 3 | 1 | 0,5 | -1 |
| 4 | 2 | 2 | +1 |
| 5 | 2,5 | 3 | -1 |

Itération 3

| <i>i</i> | <i>x</i>⁽ⁱ⁾ [m] | <i>y</i>⁽ⁱ⁾ [m] | label |
|-----------------|-----------------------------------|-----------------------------------|--------------|
| 1 | 1 | 2 | -1 |
| 2 | 1,5 | 1,5 | -1 |
| 3 | 1 | 0,5 | -1 |
| 4 | 2 | 2 | +1 |
| 5 | 2,5 | 3 | -1 |



Régression logistique vs SVM

I. Machine learning


- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM


III. ML non supervisé

- A. K-moyennes

| | Régression logistique | Séparateur à vaste marge |
|--|--|--|
| | <ul style="list-style-type: none"> • Sépare les données en plusieurs classes à l'aide d'une fonction coût au choix qui est minimisée. | <ul style="list-style-type: none"> • Maximise la marge (distance entre la frontière de décision et les vecteurs de support) afin de minimiser l'erreur de classification. |
| | <ul style="list-style-type: none"> • Approche statistique | <ul style="list-style-type: none"> • Approche géométrique |
| | <ul style="list-style-type: none"> • Adapté pour des données classifiées et indépendantes | <ul style="list-style-type: none"> • Adapté pour des données semi-structurées (texte, images, etc.) |
| | <ul style="list-style-type: none"> • peut entrer dans un biais de surapprentissage |  <ul style="list-style-type: none"> • Pas de risque de surapprentissage |

| | Nb feature >> nb data | Peu de features Peu de données | Peu de features Beaucoup de données |
|-----|-----------------------|-----------------------------------|---|
| RL | ✓ | ✓ | ✓ créer des features intermédiaires |
| SVM | ✓ | ✓ avec noyau | ✓ créer des features intermédiaires |

3 L'apprentissage non supervisé



K-moyennes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif


II. ML supervisé


- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

- Dans ce cours, nous nous intéresserons qu'à une seule technique d'apprentissage machine non-supervisé : le **partitionnement en K-moyennes** (ou *k-means* en anglais).
- Il s'agit de regrouper les points en k groupes, ou *clusters*, de façon à minimiser une fonction coût : la somme des carrés des distances entre les points et la moyenne des points de son cluster.





K-moyennes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé


- A. K-moyennes

■ Étant donné :


- un ensemble de n points $\{x^{(1)}, x^{(2)}, x^{(3)}, \dots, x^{(m)}\}$
- à partitionner en k clusters $S_k = \{S_1, S_2, \dots, S_k\} (k \leq n)$
- à partir de Mesures de distance/dissimilarité $d(x^{(i)}, x^{(j)})$

■ On peut partitionner les données comme suit :


- Par distances euclidiennes : **k-moyenne** ;
- Par distances absolues : **K-médiane** ;
- En minimisant le rayon maximum : **K-centre**.




Données d'entrée




① Initialisation



② Assignation



③ Calcul des points moyens



K-moyennes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

Démarche

❶ initialiser aléatoirement K centroïdes $\mu_1, \mu_2, \dots, \mu_K \in \mathbb{R}^n$

❷ Itérer :

Étape d'assignation des cluster

Pour $i = 1:m$

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_{c^{(i)}}\|^2$$


$c^{(i)} :=$ indice ($1 \rightarrow K$) du centroïde du cluster le plus proche de $x^{(i)}$

Étape de mise à jour des centroïdes

Pour $j = 1:K$

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_{c^{(i)}}\|^2$$

$\mu_k :=$ moyenne (mean) des points attribués au cluster k



K-moyennes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé


- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes


Choix du nombre de clusters K

- La fonction de coût diminue avec le nombre d'itérations.
- L'optimal choisi est dans la région du coude : le moins de clusters possible pour un J minimisé.



EXEMPLE

Regrouper des fruits par leurs couleurs



K-moyennes

I. Machine learning

- A. Définition
- B. Avantages
- C. Terminologie
- D. Classification
- E. Comparatif

II. ML supervisé

- A. Régression linéaire
- B. Régression logistique
- C. SVM

III. ML non supervisé

- A. K-moyennes

EXEMPLE

Séparer les sources wifi/radiofréquences d'un module NRF24L en fonction de la puissance du signal reçu.



Un capteur NRF24L reçoit les signaux de 7 autres modules eux-mêmes connectés à des Arduino, avec des distances et des messages de natures différentes.

| i | 1 | 2 | 3 | 4 | 5 | 6 | 7 |
|---------------|---|-----|-----|---|---|-----|-----|
| $x^{(i)} [m]$ | 1 | 1,5 | 1 | 2 | 1 | 1,3 | 2,1 |
| $y^{(i)} [m]$ | 2 | 1,2 | 0,5 | 2 | 3 | 2 | 4 |

→ Classer les sources en fonction de leurs puissance d'émission.

On émet l'hypothèse qu'il y a $K = 3$ centroïdes.

On initialise :

$$\mu_0 = \mu_1 = \mu_2 = 0$$

On assigne les clusters :

$$c^{(i)} = \frac{1}{7} \sum_{i=1}^7 \|x^{(i)} - \mu_c\|$$

| i | 1 | 2 | 3 | 4 | 5 | 6 | 7 |
|---------------|-----|-----|-----|-----|-----|-----|-----|
| $c^{(i)} [m]$ | 0,5 | 0,7 | 0,7 | 0,7 | 0,7 | 0,5 | 0,8 |

On met à jour les centroïdes

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_c\|^2$$

Cours 4 : Introduction à l'apprentissage machine

- L'apprentissage machine consiste à développer un modèle que l'on commence par entraîner à l'aide d'un algorithme d'optimisation en vue de minimiser les erreurs entre ce modèle et les données. Une fois entraîné, le modèle permet de faire des prédition ou de classifier des données.
- Nous avons vu deux méthodes d'apprentissage supervisé :
 - De prédiction : la régression linéaire
 - De classification : la régression logistique et le séparateur à vaste marge (SVM)
- Et une méthode d'apprentissage non-supervisé :
 - De classification : K-moyennes